한국 공공데이터를 위한 계약 기반 Medallion 파이프라인의 정량적 평가: 데이터 표준화, 분석 비용 및 재현성

오승현 [1], 이서현 [2], 엄다현 [2], 배나연 [3], 문혜성 [2]
[1] 동덕여자대학교 컴퓨터학과 학부생
[2] 동덕여자대학교 정보통계학과 학부생
[3] 동덕여자대학교 데이터사이언스 학부생
shoh041005@gmail.com, seohyun3864@gmail.com, eamji02@gmail.com, bny0627@naver.com, moonhs2918@gmail.com

Quantitative Evaluation of a Contract-Based Medallion Pipeline for Korean Public Data: Standardization, Analytical Effort, and Reproducibility

Seung-Hyun Oh[1], Seo-Hyeon Lee[2], Da-Hyeon Eom[2], Na-yeon Bae[3], Hye-Seong Moon[2]
[1]Dept. of Computer Science, Dongduk Women's University
[2]Dept. of Information Statistics, Dongduk Women's University
[3]Dept. of Data Science, Dongduk Women's University

요 약

한국의 공공데이터는 기관마다 데이터 형식과 값 표기 방식이 달라 반복적인 전처리가 필요하며, 데이터 통합과 분석 결과의 재현에도 어려움이 있다. 본 연구는 원천 데이터를 Bronze, Silver, Gold 로 구분하는 계약 기반 Medallion 아키텍처를 한국 공공데이터에 적용한 계층형 빌드 엔진 kpubdata-builder 를 구현하고, 서울 아파트 실거래가와 전월세, 공공자전거 데이터를 대상으로 기존 monolithic 방식과 비교하여 평가한다. Silver 적용 후 표현 변경률은 데이터셋별 22.5~56.8%였으며, Bronze 대비 분석 준비 코드가 감소했고, 계층 저장은 분석 또는 Gold 단계만 재계산할 때 큰 시간 이점을 보였다. 또한 동일 스냅샷의 반복 빌드는 동일한 결과를 생성했고 관측 단위가 바뀐 경우 빌드가 fail-closed 로 중단되어, 계약 기반 계층화가 일관된 분석 입력 생성과 변화 검증에 활용될 수 있음을 확인하였다.

1. 서론

공공데이터포털[1] 등을 통해 제공되는 한국의 공공데이터는 활용 가치가 높지만, 실제 분석에 바로 사용하기 어려운 경우가 많다. 기관마다 인증 방식과 응답 형식, 페이지네이션, 오류 처리 방식이 다르고, 금액과 날짜의 표기, 컬럼명, 지역 코드, 결측값 처리 기준도 일관되지 않다. 또한 API 스키마가 변경되거나 데이터가 갱신될 수 있으며, 데이터셋 간 공통 키가 부족해 데이터 통합과 결과 재현에도 어려움이 있다. 이러한 문제를 개별 스크립트로 처리하면 유사한 전처리가 반복되고 정제 기준도 달라질 수 있으며, 데이터 소스가 변경되면 기존 분석 과정 전체를 다시 수정해야 한다.

본 연구는 이러한 문제를 개선하기 위해 원천 데이터를 Bronze, Silver, Gold 로 구분하는 Medallion 아키텍처[2, 3]를 한국 공공데이터에 적용하고, 재현 가능한 계층형 빌드 엔진인 kpubdata-builder[4]를 통해 계층화에 따른 차이를 정량적으로 평가한다.

이를 위해 Silver 계층의 표현 및 구조 변화(RQ1), 계층별 준비 코드와 재계산 비용(RQ2), 고정된 계약에서의 재현 범위와 데이터 변경 시 동작(RQ3)을 연구 질문으로 설정한다.

본 연구의 기여는 다음과 같다. 첫째, 한국 공공데이터를 위한 계약 기반 Medallion 파이프라인을 구현하고 kpubdata-builder 를 통해 실증적으로 평가한다. 둘째, Bronze, Silver, Gold 로 계층화한 방식과 중간 계층을 별도로 저장하지 않는 monolithic 방식을 동일한 분석 과제에서 비교하여 계층화에 따른 차이를 정량적으로 평가한다. 셋째, 데이터셋, 소스 스냅샷, 실험 코드와 결과를 공개하여[4] 연구 결과를 재현하고 검증할 수 있도록 한다.

2. 관련연구

Lakehouse[2]는 데이터 레이크의 개방적 저장 방식에 데이터 웨어하우스의 관리 및 품질 기능을 결합한 구조이고, Medallion 아키텍처[3]는 처리 단계에 따라 데이터를 Bronze, Silver, Gold 로 나눈다. Bronze 에는 원천 데이터를 보존하고, Silver 에서는 정제와 표준화를 수행하며, Gold 에서는 분석 목적에 맞는 형태로 데이터를 가공한다. 이러한 계층 구조는 처리 과정을 단계별로 관리하기 쉽지만, 각 계층을 실제로 저장했을 때 분석 준비와 재계산 과정에서 어떤 차이가 생기는지는 별도로 확인할 필요가 있다.

데이터 품질은 완전성, 유효성, 일관성, 정확성 등 여러 측면에서 평가할 수 있다[5]. 재현성을 위해서는 데이터 버전 관리, 결정적 빌드와 데이터 계보가 필요하다. 본 연구는 데이터셋의 출처와 생성 과정 기록을 강조한 선행 연구[6]를 바탕으로 품질 지표와 Manifest 에 기록된 입력 데이터의 해시값· 실행 정보를 활용하여 계층 변환과 반복 빌드를 검증한다.

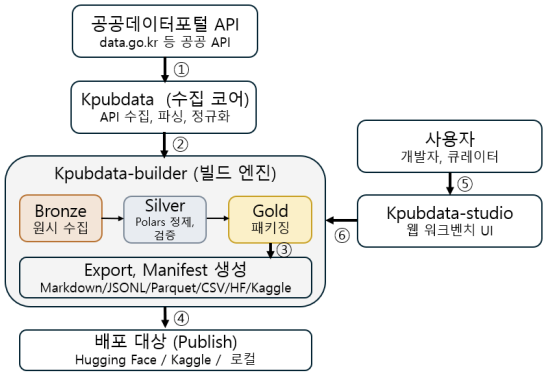
공공데이터의 품질과 활용에 관한 연구가 지속적으로 이루어져 왔으나[7, 8], 공공데이터를 분석 가능한 형태로 변환하는 과정에서 계층화에 따른 데이터 표준화, 분석 비용 및 재현성의 차이를 동일한 조건에서 비교한 연구는 제한적이다. 이에 본 연구는 한국 공공데이터에 Bronze, Silver, Gold 계층을 적용하고 각 계층과 monolithic 방식을 비교한다.

3. 계약 기반 Medallion 파이프라인 구현

kpubdata 제품군[4]은 데이터 수집을 담당하는 kpubdata, 빌드 엔진인 kpubdata-builder, 웹 기반 UI 인 kpubdata-studio 로 구성된다. 본 연구에서는 Python 과 Polars 기반으로 구현된 kpubdata-builder 를 중심으로 실험하며, 선언적 BuildSpec 에 따라 Validate, Preview, Build, Publish 과정을 거쳐 데이터를 Bronze, Silver, Gold 계층으로 처리한다(그림 1).

Bronze 는 수집된 원천 레코드의 필드명과 값을 변경하지 않고 수집 시각, 요청 정보, 레코드 수 등의 메타데이터와 함께 보존하여 이후 계층 변환의 기준으로 사용한다. Silver 는 BuildSpec 의 스키마와 변환 규칙을 적용하여 필수 컬럼, 자료형, 금액, 날짜, 식별자 및 결측값을 검증하고 표준화한다. 또한 결측률, 중복률, 행 수, 값 범위 등의 품질 기준을 PASS, WARN, FAIL 로 평가하고 이전 빌드와 비교하여 스키마 변화를 탐지한다. Gold 는 Silver 데이터를 기반으로 과제별 분할, 조인, 집계 및 파생 변수 생성을 수행하고, 특정 분석의 최종 결과가 아닌 후속 분석용 입력 데이터로 저장한다.

각 빌드는 레코드 수, 소스 체크섬, 입력 데이터의 SHA-256 해시, 실행 환경, 품질 및 스키마 변화 결과를 Manifest 에 기록한다. 이를 통해 동일 입력의 재빌드 결과를 확인하고 변경 원인을 추적할 수 있도록 한다.



<그림 1> kpubdata 제품군과 kpubdata-builder 의 Medallion 구조

4. 실험 설계

4.1 데이터셋

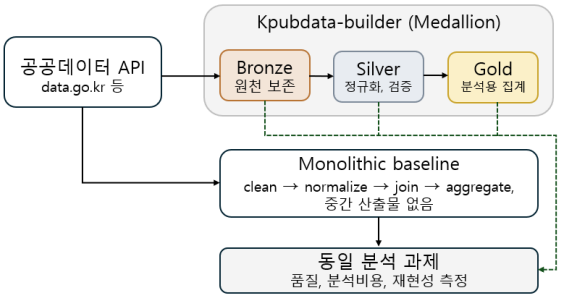
실험에는 서울 25 개 자치구의 2020~2024 년 아파트 실거래가와 전월세 데이터, 서울시 공공자전거(따릉이) 데이터를 사용한다(표 1). 따릉이 데이터는 G1, G2, I1, G3, G4 의 다섯 배포 세대로 구분되며, RQ1 에는 G4 를 제외한 통합본을, RQ3 의 소스 진화 실험(R2)에는 세대별 원천을 사용하였다. 모든 데이터는 실험 시점의 스냅샷으로 고정하고 체크섬을 기록한다.

<표 1> 실험 데이터셋

데이터셋	기간	원천 행 수	용도
아파트 실거래	2020~2024	233,596	T1,T3,RQ1,R1,변형
아파트 전월세	2020~2024	1,221,491	T3, RQ1
따릉이 월별 대여	2020~2023	4,902,236	RQ1, R2

4.2 비교 조건과 기준선

비교 조건은 Bronze, Silver, Gold, monolithic 의 네 가지이다(그림 2). Bronze, Silver, Gold 조건은 각 계층에 저장된 산출물을 분석 입력으로 사용한다. 반면, monolithic 기준선은 Bronze 데이터를 입력받아 정제, 표준화, 조인, 집계를 하나의 파이프라인에서 수행하고 중간 계층을 별도로 저장하지 않는다. 모든 조건은 API 를 재호출하지 않고 동일한 Bronze 스냅샷에서 시작하며, 동일한 변환 규칙과 분석 함수를 적용한다. 조건별 output_hash 로 분석 결과의 일치 여부를 확인한 후 비용을 측정한다.



<그림 2> 실험 설계: 계층별 조건과 monolithic 기준선

4.3 분석 과제

데이터 집계와 데이터셋 조인의 두 과제를 구성하며, 실험 저장소에서는 각각 T1 과 T3 으로 식별한다. 가격 집계 과제(T1)는 서울 아파트 실거래가를 자치구와 월 단위로 집계하여 평균 가격, 중앙 가격, 거래 건수를 산출하고 기간별 가격 추세와 지역별 차이를 비교한다. 매매·전월세 조인 과제(T3)는 두 원천을 지역, 아파트, 시점, 면적 기준으로 조인하여 자치구별 월간 전세가율을 산출하고, 동일한 결과에 도달하기 위한 계층별 준비 비용과 조인 매칭 특성을 비교한다.

4.4 평가 지표

RQ1 의 데이터 표현 변화는 Bronze 와 Silver 의 대응 셀을 비교해 변경된 셀의 비율과 원인을 측정한다. 변경 원인은 타입 정규화, 수치 형식, 식별자 자릿수, 연월 표기, 결측 표기, 파생 필드의 여섯 가지로 사전에 정의하였다.

RQ2 에서는 입력을 분석 가능한 형태로 만드는 준비 비용을 비교한다. 각 조건의 prepare() 메서드에서 코드 길이(LOC)와 변환 함수 수를 측정하고, 분석 함수는 네 조건에서 동일하게 유지한다. 재계산 시간은 무효화 범위에 따라 S1(분석), S2(Gold), S3(Silver), S4(원천)로 나누어 pandas 와 Polars 에서 warm-up 1 회 후 5 회 측정한 중앙값을 사용한다.

RQ3 은 반복 빌드와 데이터 변경에 대한 계약의 동작을 확인한다. R1 에서는 동일한 스냅샷·계약·빌더로 10 회 재빌드하여 다이제스트 일치 여부를 확인하고, R2 에서는 하나의 고정된 계약으로 따릉이 다섯 세대를 순차 빌드해 실패 지점을 기록한다. 또한 원천 데이터에 통제된 변형 51 건을 적용하여 의미 파괴 변형 20 건의 거부 여부와 의미 보존 변형 31 건의 통과 여부를 확인한다. 모든 결과는 기술통계로 정리하며, 표본 구성과 실험 목적을 고려하여 추론통계는 사용하지 않는다.

5. 실험 결과 및 논의

5.1 데이터 표현 변화 (RQ1)

<표 2> 데이터셋별 표현 변경률과 주요 변경 원인

데이터셋	역할 셀(백만)	변경 셀(백만)	변경률 (%)	주요 변경 원인
실거래	4.91	1.17	23.8	타입 정규화, 수치 형식, 파생
전월세	21.99	4.94	22.5	타입 정규화, 수치 형식, 파생
따릉이	53.92	30.65	56.8	타입 정규화, 식별자 자릿수, 연월 및 결측 표기

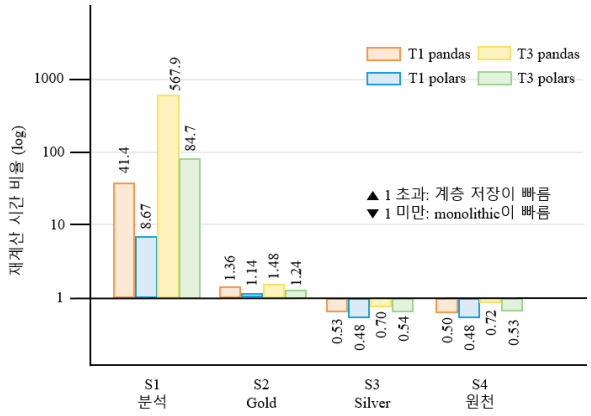
Silver 변환 후 변경률은 실거래 23.8%, 전월세 22.5%, 따릉이 56.8%였다. 특히 따릉이는 배포 세대마다 대여소 식별자 자릿수, 연월 및 결측값 표기가 달라 변경률이 높았으며, 이는 Silver 계약이 서로 다른 원천 표현을 공통 분석 스키마로 정규화했음을 보여준다.

5.2 분석 비용 (RQ2)

<표 3> 과제 및 조건별 데이터 준비 비용

과제	조건	LOC	함수	단계
T1	Bronze	20	6	7
	Silver	12	3	3
	Gold	2	0	0
	Monolithic	16	6	1
T3	Bronze	50	13	7
	Silver	34	10	4
	Gold	2	0	0
	Monolithic	46	13	1

네 조건은 모두 동일한 output_hash 를 생성하였다. Bronze 대비 Silver 의 준비 코드는 T1 에서 20 행에서 12 행으로, T3 에서 50 행에서 34 행으로 감소하였으며, 계측 행을 제외한 민감도 분석에서도 같은 경향이 나타났다. 또한 Gold 에서는 과제별 전처리가 빌드 단계로 이동하여 두 과제 모두 2 행으로 줄었다. 다만 monolithic 과 비교하면 계층화가 항상 준비 코드를 줄이는 것은 아니었다. T3 의 조인 매칭률은 0.634 였으며, 결과는 매칭된 키를 기준으로 산출하였다.



<그림 3> 재계산 시간 비율

(monolithic ÷ 계층 저장, 1 보다 크면 계층화가 빠름)

분석 또는 Gold 만 다시 계산하는 S1, S2 에서는 계층 저장 방식이 더 빨랐고, T3 pandas 에서는 최대 567.9 배의 차이가 나타났다. 반면 Silver 또는 원천까지 무효화되는 S3, S4 에서는 체크포인트 처리 비용으로 비율이 0.48~0.72 배로 역전되었다. 즉, 계층 저장의 재계산 이점은 재사용 가능한 중간 산출물의 범위가 클수록 두드러졌다. 한편 Bronze 와 Silver 동시 저장은 Silver 단독 대비 약 1.9 배의 저장 공간이 필요하였다.

5.3 재현성과 계약의 경계 (RQ3)

<표 4> 재현성과 변형 실험 결과

실험	결과
R1: 10 회 재빌드	10/10 성공, 다이제스트 1 개, canonical Silver 와 바이트 일치
R2: G1, G2, I1, G3, 통합본	행 손실 없이 통과
R2: G4	Silver/coalesce 단계에서 fail-closed 중단
의미 파괴 변형 20 건	12 건 거부, 8 건 통과
의미 보존 변형 31 건	26 건 수용, 4 건 오거부, 1 건 값이 바뀐 채 통과

동일한 스냅샷과 계약을 사용한 10 회 재빌드는 모두 canonical Silver 와 바이트 단위로 일치하였다. 관측 단위가 변경된 G4 에서는 빌드가 fail-closed 로 중단되어 구조적 변화를 차단하였다. 변형 실험에서는 51 건 중 38 건이 의도대로 처리되었다. 통과한 의미 파괴 변형 8 건 중 5 건은 계약으로 표현 가능하지만 선언되지 않은 경우였고, 3 건은 현재 계약 범위 밖이었다. 의미 보존 변형에서도 오거부 4 건과 값 변경 통과 1 건이 발생하여 추가 검증 규칙이 필요한 지점을 확인하였다.

6. 결론 및 향후 연구

본 연구는 kpubdata-builder 를 통해 계약 기반 Medallion 파이프라인의 효과를 평가하였다. Silver 단계에서 이질적인 표현을 공통 스키마로 정규화하면서 준비 코드가 감소했고, 재사용 가능한 중간 산출물이 남는 경우 재계산 비용도 크게 줄었다. 반복 빌드는 같은 결과를 생성했고 관측 단위 변화는 차단되었지만, 일부 변형에서 오거부와 오수용이 발생해 현재 계약만으로 모든 변화를 구분하기에는 한계가 있었다. 향후 다양한 지역과 분야의 공공데이터로 실험을 확대하고, 스키마 변화 자동 대응, 증분 빌드, 데이터 계보 추적 및 kpubdata-studio 기반 품질 검증 기능을 추가할 예정이다.

사사

※ 본 논문은 과학기술정보통신부
대학디지털교육역량강화사업의 지원을 통해 수행한
한이음 드림업 프로젝트 결과물입니다.

참고문헌

[1] 행정안전부, 공공데이터포털, https://www.data.go.kr.
[2] M. Armbrust, A. Ghodsi, R. Xin, and M. Zaharia, "Lakehouse: A New Generation of Open Platforms that Unify Data Warehousing and Advanced Analytics," Proc. CIDR, 2021.
[3] Databricks, Medallion Architecture, databricks.com/glossary/medallion-architecture.
[4] Y. Choe, kpubdata·kpubdata-builder, github.com/yeongseon.
[5] R. Y. Wang and D. M. Strong, "Beyond Accuracy: What Data Quality Means to Data Consumers," J. Manag. Inf. Syst., Vol. 12, No. 4, pp. 5-33, 1996.
[6] T. Gebru et al., "Datasheets for Datasets," Commun. ACM, Vol. 64, No. 12, pp. 86-92, 2021.
[7] 박고은, 김창재, "공공개방데이터 품질 특성에 관한 연구," 디지털융복합연구, Vol. 13, No. 10, pp. 135-146, 2015.
[8] 김학래, "공공데이터 개방표준 데이터의 품질평가," 한국콘텐츠학회논문지, Vol. 20, No. 9, pp. 439-447, 2020.